Maestría en Explotación de Datos
y Descubrimiento del Conocimiento
Universidad de Buenos Aires

Web scraping

Gustavo Juantorena [contacto] ✳ 26/08/21

LIAA
Laboratorio de Inteligencia Artificial Aplicada

Hoja de ruta

1. ¿Qué es el web scraping?
2. ¿Qué son las APIs?
3. ¿Cuándo conviene usar cada cosa?
4. Breve introducción a las tecnologías web necesarias
5. Web Scraping con Python básico
6. Web scraping “avanzado”
7. Práctica en Google Colab

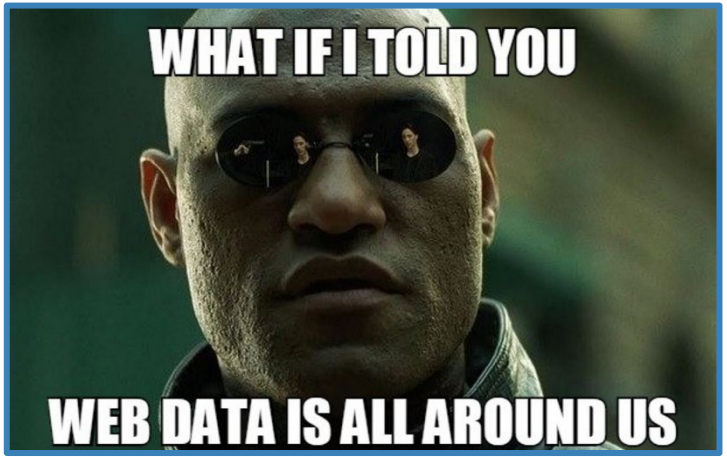

¿Qué es el web scraping?

*La práctica de **recopilar datos** a través de cualquier medio que no sea un programa que interactúa con una API o un humano que usa un navegador web. **Normalmente mediante un programa automatizado que consulta un servidor web**, solicita datos (generalmente en forma de HTML y otros archivos que componen las páginas web) y luego analiza esos datos para extraer la información necesaria.*

¿Qué es el web scraping?

*La práctica de **recopilar datos** a través de cualquier medio que no sea un programa que interactúa con una API o un humano que usa un navegador web. **Normalmente mediante un programa automatizado que consulta un servidor web**, solicita datos (generalmente en forma de HTML y otros archivos que componen las páginas web) y luego analiza esos datos para extraer la información necesaria.*

*El **web crawling** o indexación, se utiliza para indexar la información de la página mediante bots también conocidos como crawlers (lo que hacen los motores de búsqueda). Se trata de ver una página como un todo e indexarla. Cuando un bot rastrea un sitio web, recorre todas las páginas y todos los enlaces, hasta la última línea del sitio web, en busca de **CUALQUIER información**.*

Disclaimer

Legality and Ethics of Web Scraping

Emergent Research Forum (ERF)

Vlad Krotov
Murray State University
vkrotov@murraystate.edu

Leiser Silva
University of Houston
lsivla@uh.edu

- Is Web Crawling or Web Scraping explicitly prohibited by the website's "terms of use" policy?
- Is the website's data explicitly copyrighted?
- Does the project involve illegal or fraudulent use of the data?
- Can crawling and scraping potentially cause material damage to the website or Web server hosting the website?
- Can the data obtained from the website compromise individual privacy?
- Can the data obtained from the website reveal confidential information about operations of the organizations providing data or the company owning the website?
- Can the project requiring the Web data potentially diminish the value of the service provided by the website?

Fuente:
https://www.researchgate.net/profile/Vlad-Krotov/publication/324907302_Legality_and_Ethics_of_Web_Scraping/links/5aea622345851588dd8287dc/Legality-and-Ethics-of-Web-Scraping.pdf

API (Interfaz de programación de aplicaciones)

Conjunto de funciones, métodos y protocolos de comunicación que ofrece un programa para ser utilizado por otro.

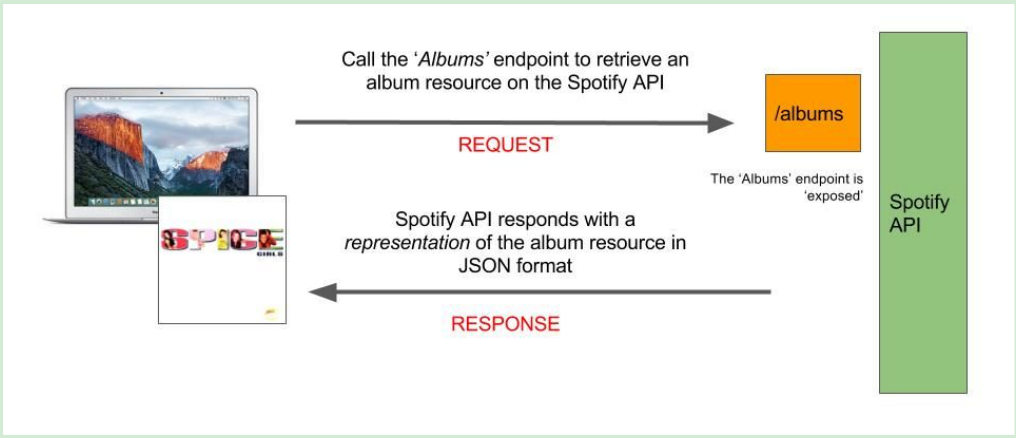

Nos provee el contenido con un determinado formato y especifica las limitaciones (ej: cantidad de pedidos al servidor).

Ejemplos de APIs

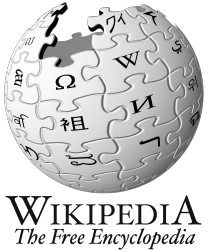

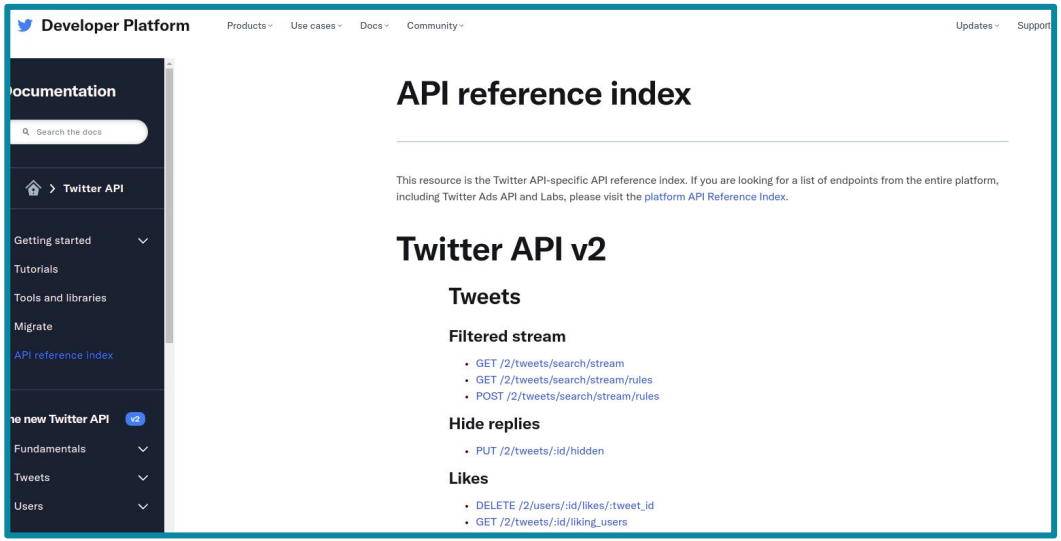

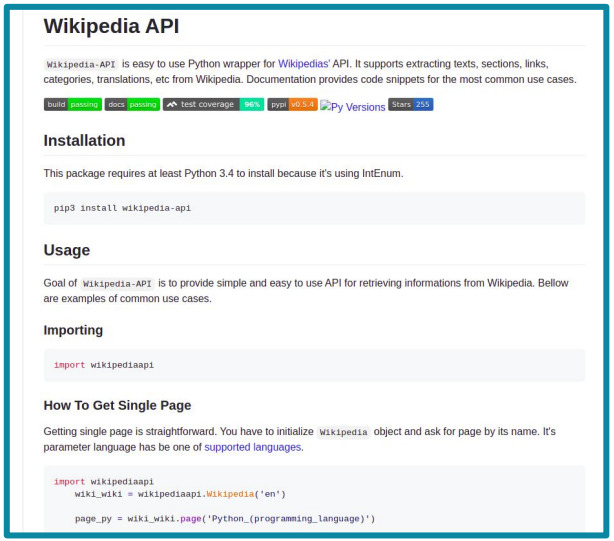

API vs Web scraping (I)

Web scraping	API
Extraer información de un sitio web usando un programa informático.	Proveer acceso a los datos de una aplicación, sistema operativo u otro servicio.

Mismo objetivo: Acceder a los datos del sitio web

API vs Web scraping (II)

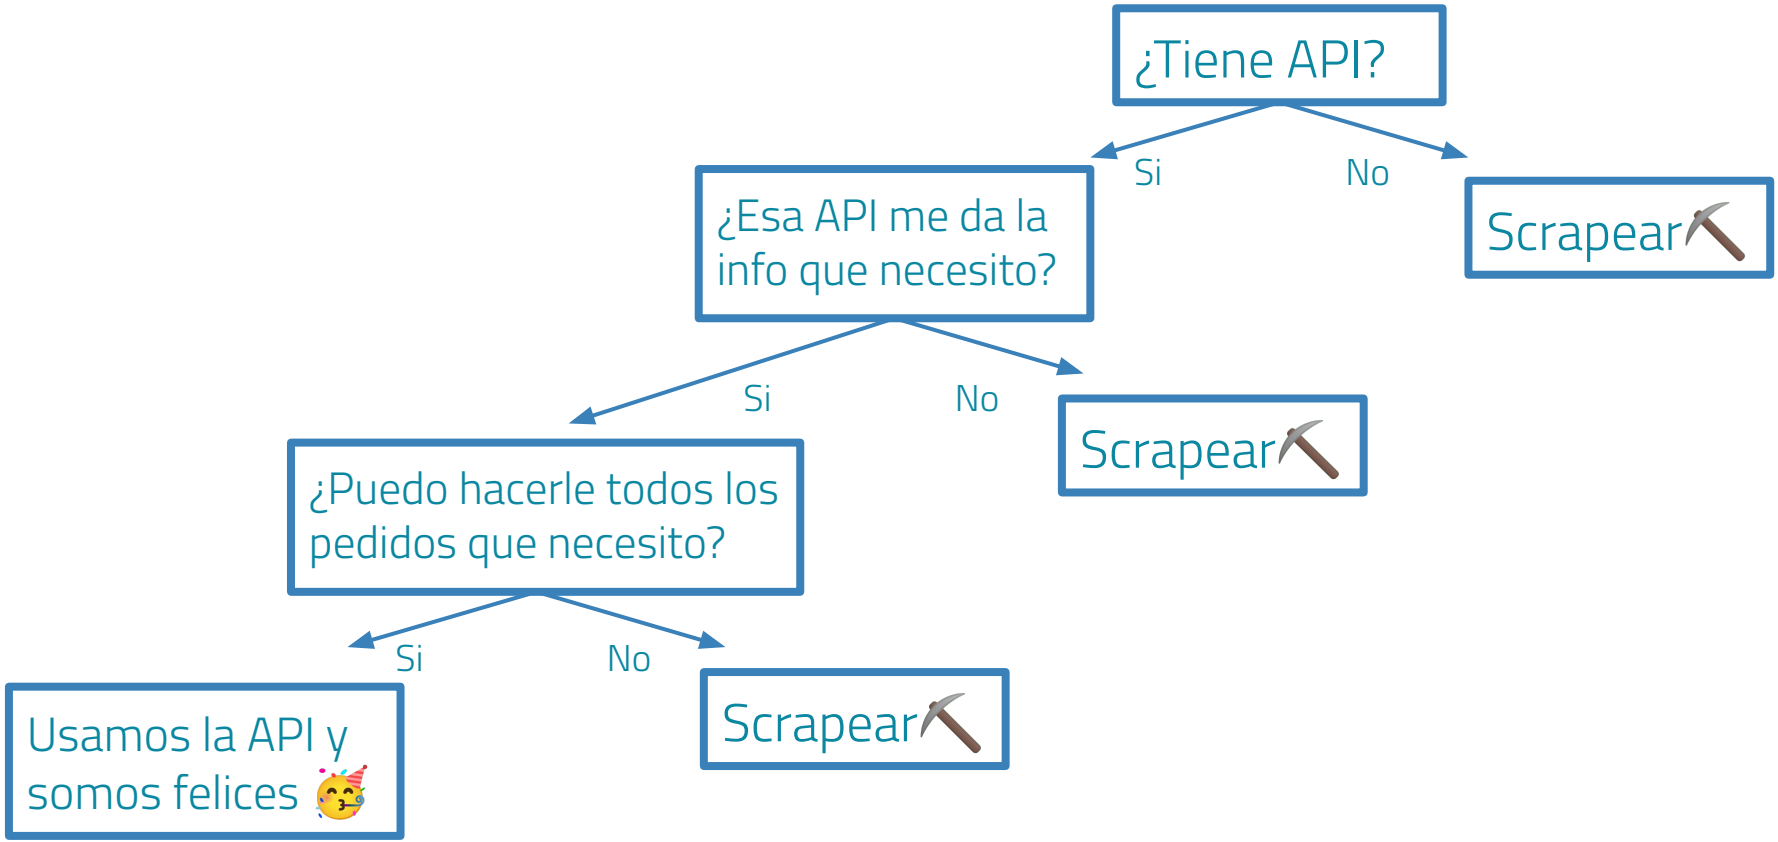

Conceptos básicos sobre la web (I)

- **HTTPS** (Protocolo seguro de transferencia de hipertexto): Protocolo de mensajería que permite a los navegadores web comunicarse con los servidores web (donde se almacenan los sitios web).

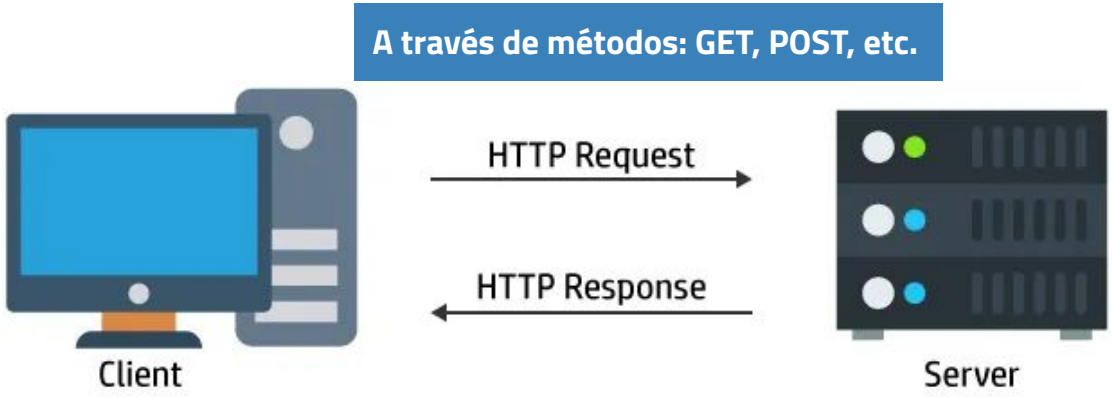

Fig: HTTP Protocol

Conceptos básicos sobre la web (II)

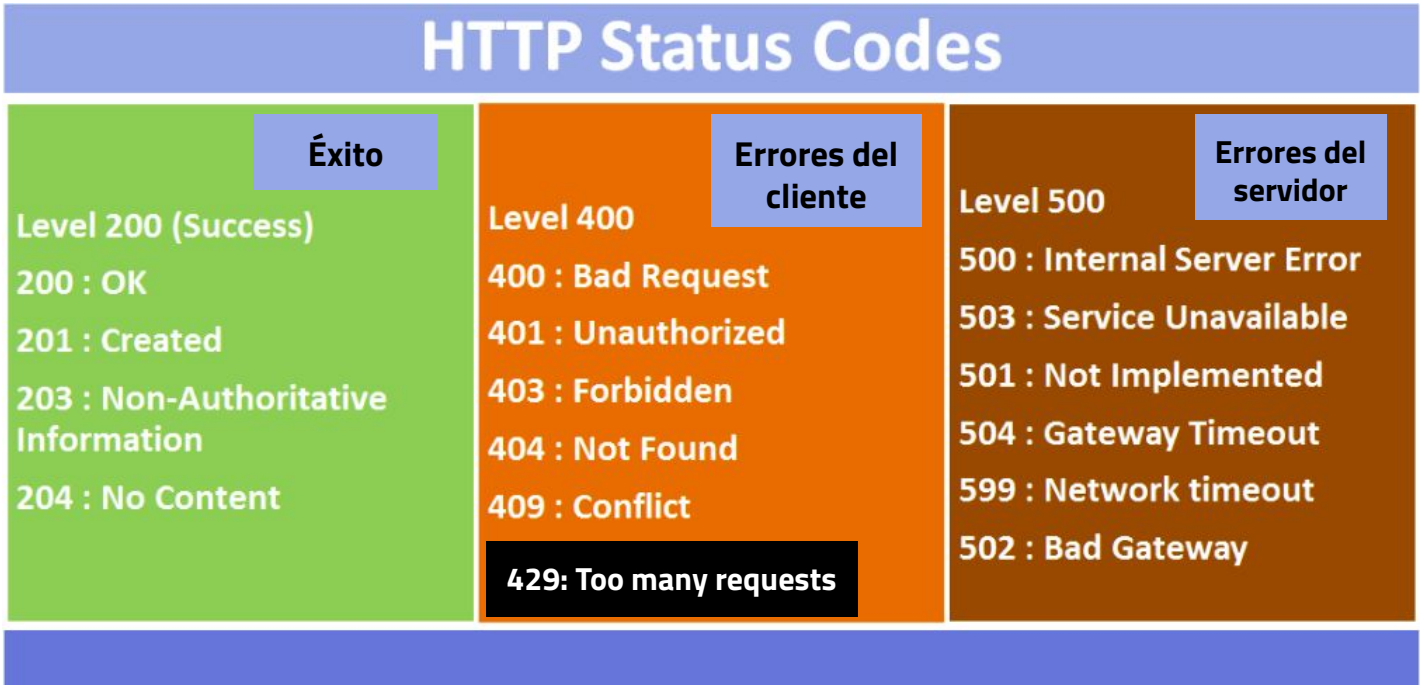

Fuente: https://gabicuesta.blogspot.com/2019/01/http-status-codes.html

Conceptos básicos sobre la web (III)

comma-separated values

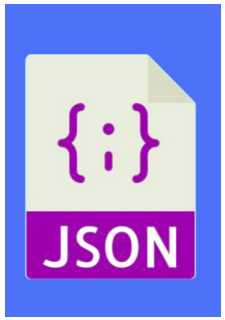

Javascript Object Notation

```
album, año, ranking
The White Stripes, 1999, 2
De Stijl, 2000, 3
Lo mejor del amor, 1996, 1
```

```
[
  {
    "album": "The White Stripes",
    "año": 1999,
    "ranking": 2
  },
  {
    "album": "De Stijl",
    "año": 2000,
    "ranking": 3
  },
  {
    "album": "Lo mejor del amor",
    "año": 1996,
    "ranking": 1
  }
]
```

https://csvjson.com/csv2json

Conceptos básicos sobre la web (III)

comma-separated va

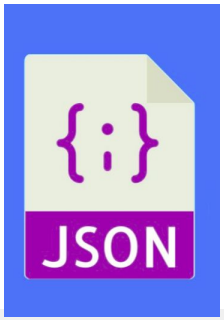

Javascript Object Notation

```
album, año, ranking
The White Stripes, 1999, 2
De Stijl, 2000, 3
Lo mejor del amor, 1996, 1
```

```
<?xml version="1.0" encoding="UTF-8"?>
<root>
 <element>
  <album>The White Stripes</album>
  <year number="true">1999</year>
  <ranking number="true">2</ranking>
 </element>
 <element>
  <album>De Stijl</album>
  <year number="true">2000</year>
  <ranking number="true">3</ranking>
 </element>
 <element>
  <album>Lo mejor del amor</album>
  <year number="true">1996</year>
  <ranking number="true">1</ranking>
 </element>
</root>
```

```
"The White Stripes",
99,
: 2

"De Stijl",
00,
: 3

"Lo mejor del amor",
96,
: 1
```

https://csvjson.com/csv2jso

https://www.utilities-online.info/xmltojson

Conceptos básicos sobre la web (IV)

- **HTML, CSS y JavaScript son los tres lenguajes principales con los que está hecho la parte de la web que vemos.**

Conceptos básicos sobre la web (IV)

- **HTML, CSS y JavaScript son los 3 lenguajes principales con los que estan hecho la parte de la web que vemos.**

Estructura **Funcionalidad** **Estilo**

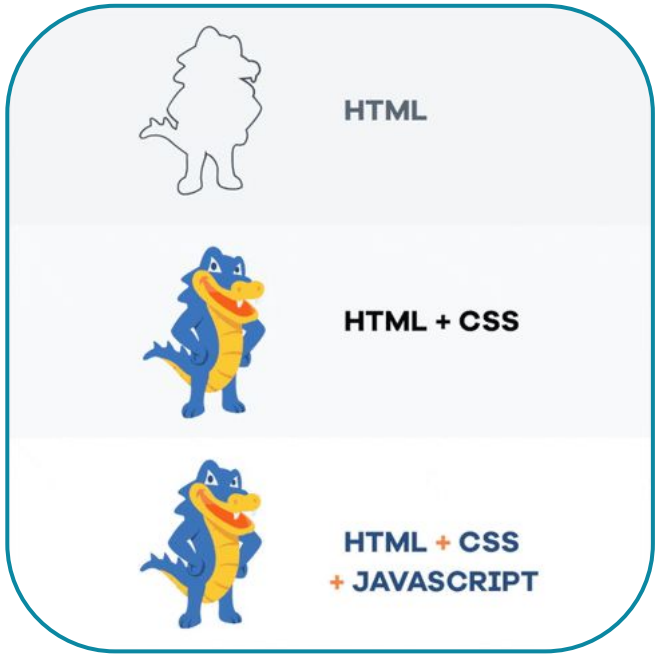

Fuente: https://geekflare.com/es/css-formatting-optimization-tools/

HTML: Lenguaje de marcado de hipertexto
CSS: Hojas de estilo en cascada

```
<!DOCTYPE html>
<html>
  <head>
      <title>Mi primer página</title>
  </head>
  <body>

      <h1>Título</h1>
      <h2 style='color:red;'> Subtitulo en rojo</h2>
      <p>Primer párrafo.</p>
      <hr>

        <h3>Gatito<h3>
        <img style='width: 100px;'
src='https://i.pinimg.com/originals/d4/8d/07/d48d074f8c
9ec84486128222956867 54.jpg' >


  </body>
</html>
```

HTML: Lenguaje de marcado de hipertexto
CSS: Hojas de estilo en cascada

```
<!DOCTYPE html>
<html>
  <head>
       <title>Mi primer página</title>
  </head>
  <body>

       <h1>Título</h1>
       <h2 style='color:red;'> Subtitulo en rojo</h2>
       <p>Primer párrafo.</p>
       <hr>

         <h3>Gatito<h3>
         <img style='width: 100px;'
src='https://i.pinimg.com/originals/d4/8d/07/d48d074f8c
9ec84486128222956867 54.jpg' >


  </body>
</html>
```

HTML TAG

CSS

HTML ATTRIBUTE

[Ir a probar el código]

DOM (Document Object Model)

Interfaz independiente del lenguaje que trata un documento XML o HTML como una estructura de árbol

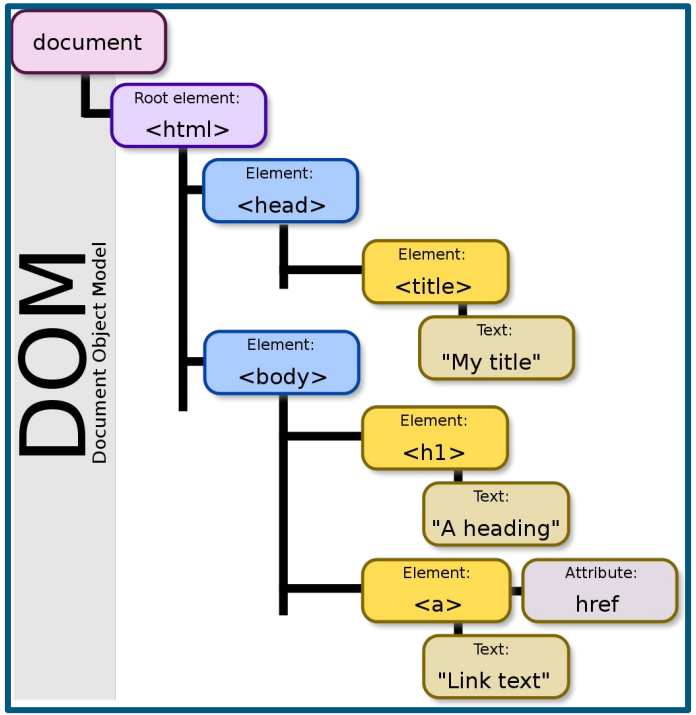

Fuente: https://en.wikipedia.org/wiki/Document_Object_Model
Autor: Birger Eriksson

JavaScript

- Permite usar un paradigma de programación orientado a eventos (entre otros).
- Más del 97% de las páginas web lo usan para generar comportamientos interactivos.

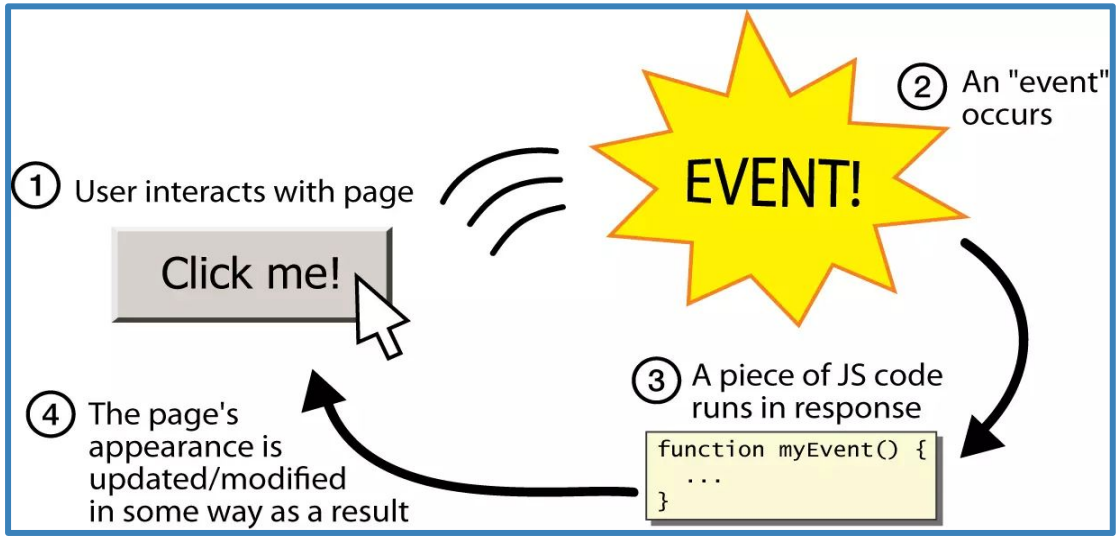

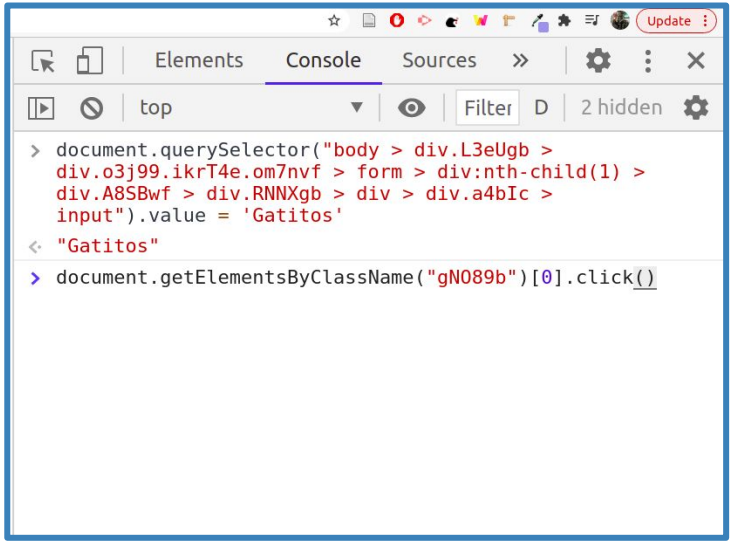

https://itzone.com.vn/en/article/event-in-javascript/

```
document.querySelector("body > div.L3eUgb > div.o3j99.ikrT4e.om7nvf > form > div:nth-child(1) > div.A8SBwf > div.RNNXgb > div > div.a4bIc > input").value = 'Gatitos'

document.getElementsByClassName("gNO89b")[0].click()
```

Xpath (XML Path Language)

Para aprender más sobre el tema:
[The W3Schools XPath Tutorial]

- **Es un lenguaje que permite construir expresiones que recorren y procesan un documento XML.**
- **La idea es parecida a las expresiones regulares para seleccionar partes de un texto sin atributos (plain text)**

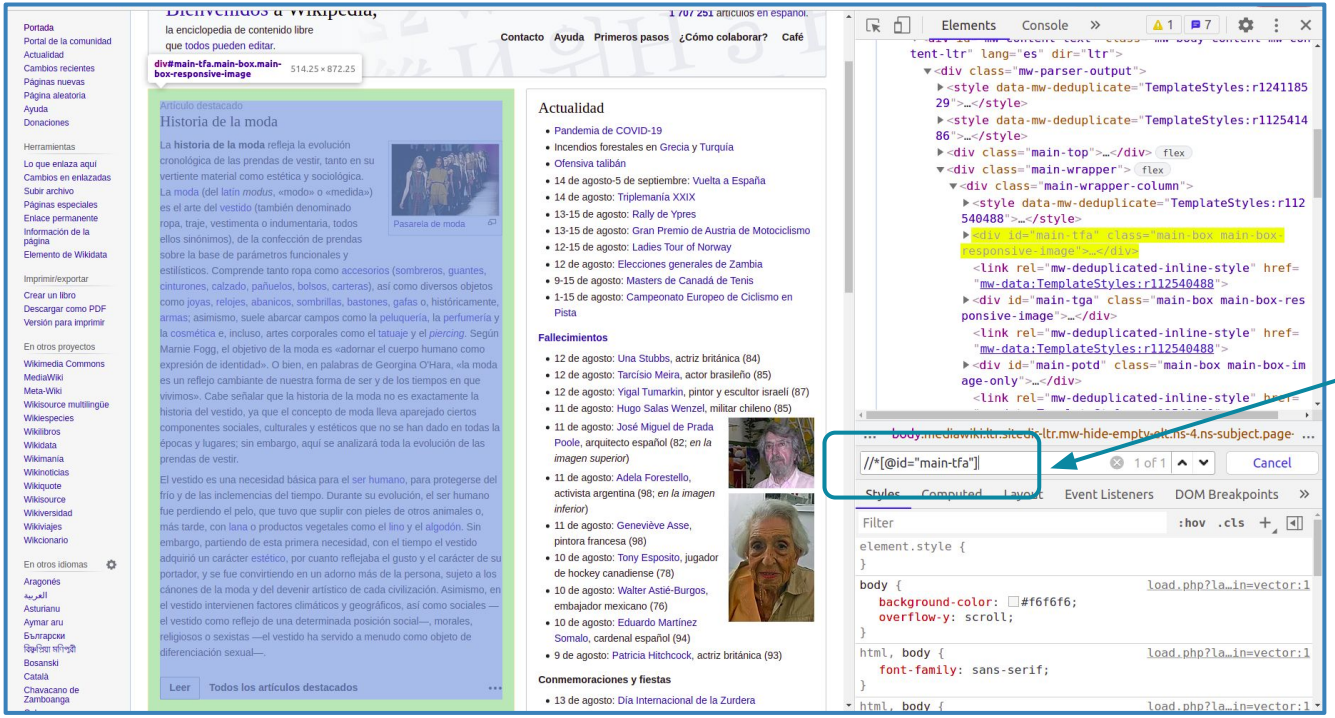

CSS selectors

Para aprender más sobre el tema:
CSS Selectors

- Los selectores CSS se utilizan para "buscar" (o seleccionar) los elementos HTML y aplicarles estilo.
- Podemos aprovecharlos para seleccionar lo que queramos scrapear.

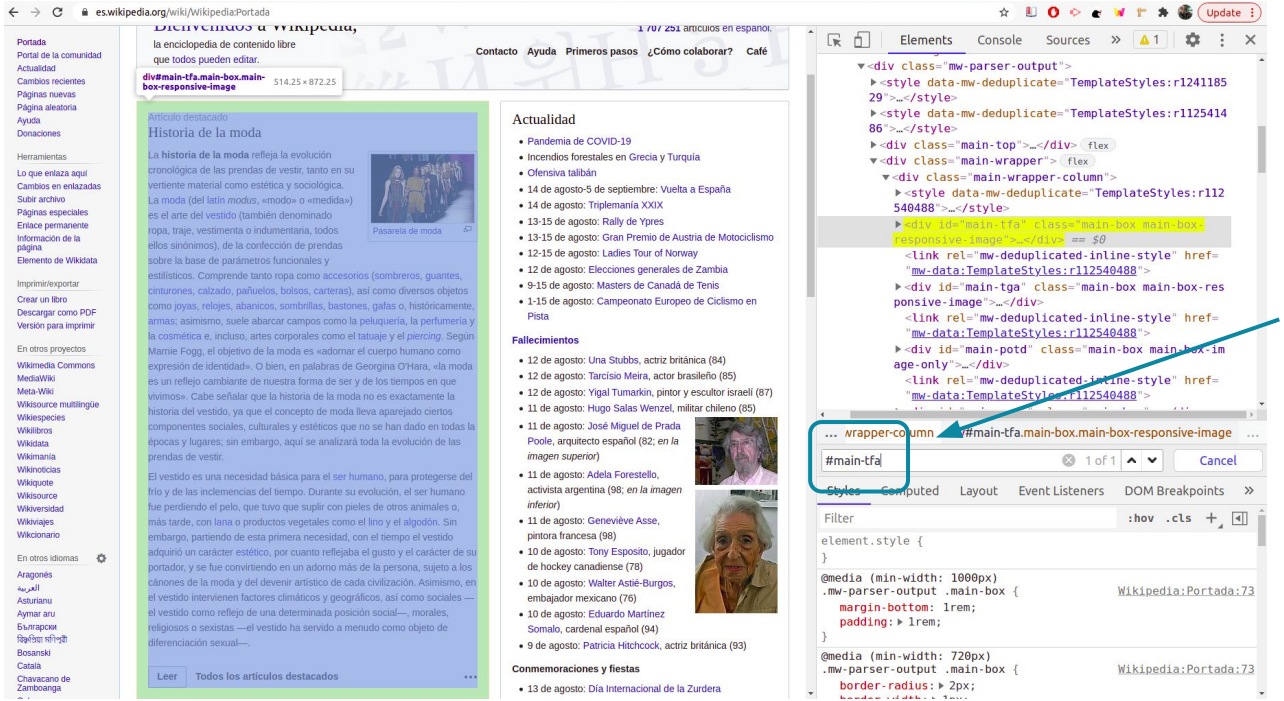

Uso de herramientas de desarrollador en el navegador

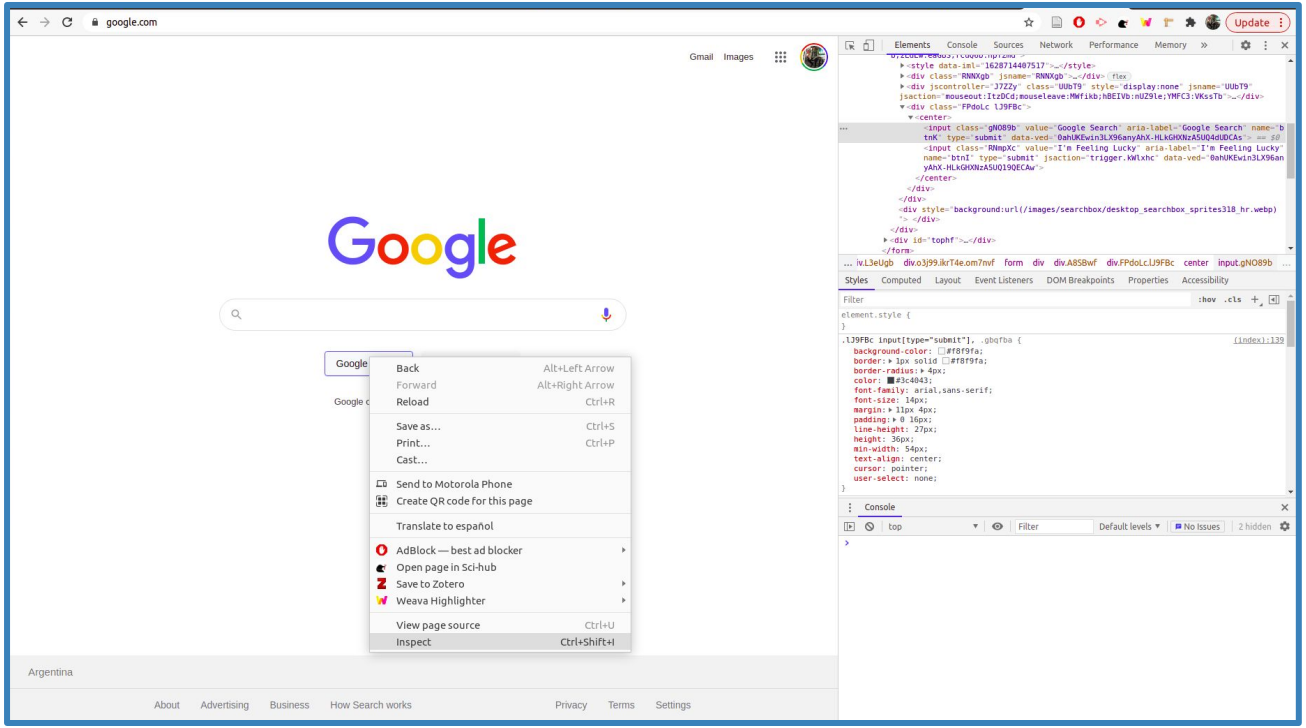

Practiquemos ...

¿¿¿Y el Python???

🐍 Web scraping con Python

- Python no es la única tecnología con la cual podemos hacer scraping (ej: R, JavaScript, Java, C++, etc)

R

Java

JavaScript

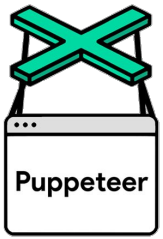

- Python nos puede ayudar en muchas cosas:
  - Pedidos HTTP (urllib, requests)
  - Parseo de la información (Beautiful Soup)
  - Automatización
  - Control de excepciones
  - etc

”Parsear” la información

- Dividir un texto en sus componentes y describir sus roles sintácticos.

- El “parseo” de un documento HTML es básicamente tomar código HTML y extraer información relevante como el título de la página, párrafos en la página, encabezados en la página, enlaces, texto en negrita, etc.

Fuente: https://stackoverflow.com/a/20421508

Pipeline web scraping

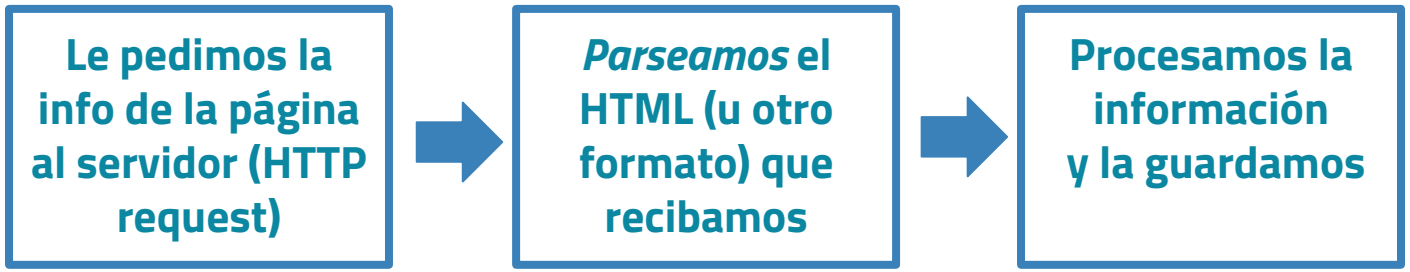

Parseando con Python: Beautiful Soup

- Beautiful Soup es una librería de Python para web scraping
- Se usa para extraer los datos de archivos HTML y XML. Crea un árbol de análisis a partir del código fuente de la página que se puede utilizar para extraer datos de forma jerárquica y más legible.

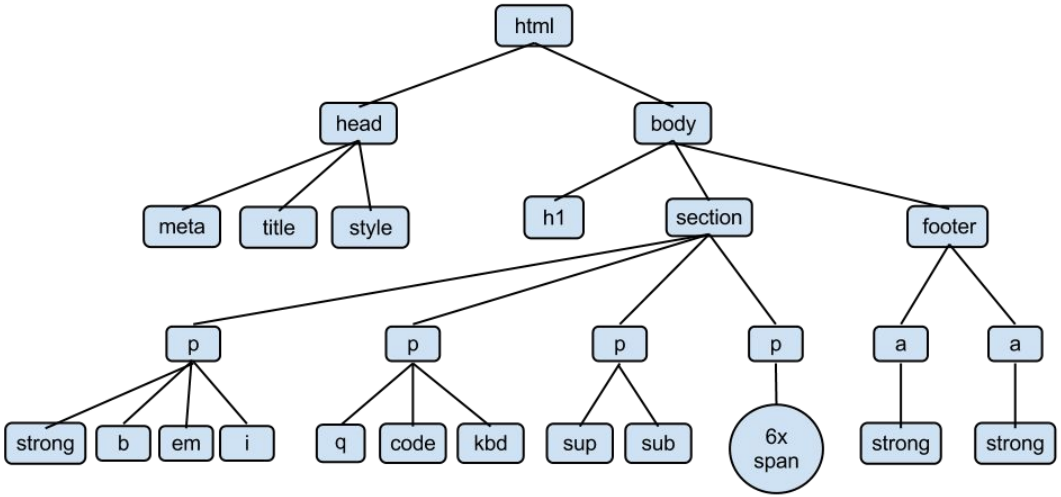

Fuente: https://medium.com/milooproject/python-simple-crawling-using-beautifulsoup-8247657c2de5

Web Scraping “avanzado” / web crawling

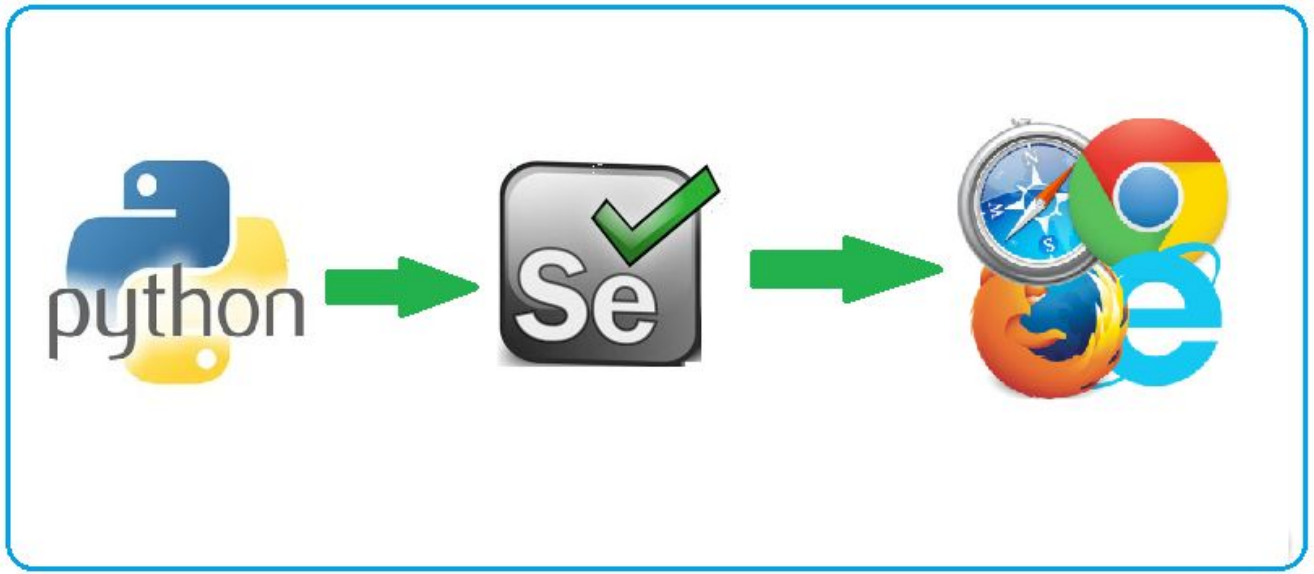

Fuente: https://medium.com/swlh/get-started-with-selenium-webdriver-in-under-5-minutes-f9b91e2e9539

Selenium

- Es una herramienta de testing y automatización que tiene una API para Python (entre otros lenguajes)

- No fue pensado específicamente para web scraping ni web crawling, pero gracias al sistema cliente/servidor **Web Driver** permite utilizar un navegador de forma local o en remoto.
    - Esto nos da acceso a un navegador “headless” (sin interfaz gráfica) con el que podemos recorrer la web.

- ¿Qué viene a solucionar respecto a lo que vimos antes?
    - Páginas dinámicas
    - Scrolleo infinito
    - Completar formularios, autenticación, pop ups, captcha, etc ...

Referencias

https://github.com/GEJ1/web-scraping-python

Web scraping con Python ⛏️

Recursos básicos para iniciarse en web scraping usando Python.

Clase dictada por Gustavo Juantorena como docente invitado en la materia **Text Mining** de la Maestría en Explotación de Datos y Descubrimiento de Conocimiento de la Universidad de Buenos Aires. El contenido aquí expuesto excede lo que se vió en a clase, pero me parece que está bueno que lo tengan como referencia para profundizar los contenidos.

- Slides de la clase
- Notebook de la clase

Recursos

- Web general
- Web scraping general
- Beautiful Soup
- Selenium
- Scrapy
- Libros

Ahora si: ¡Vamos a Colab!